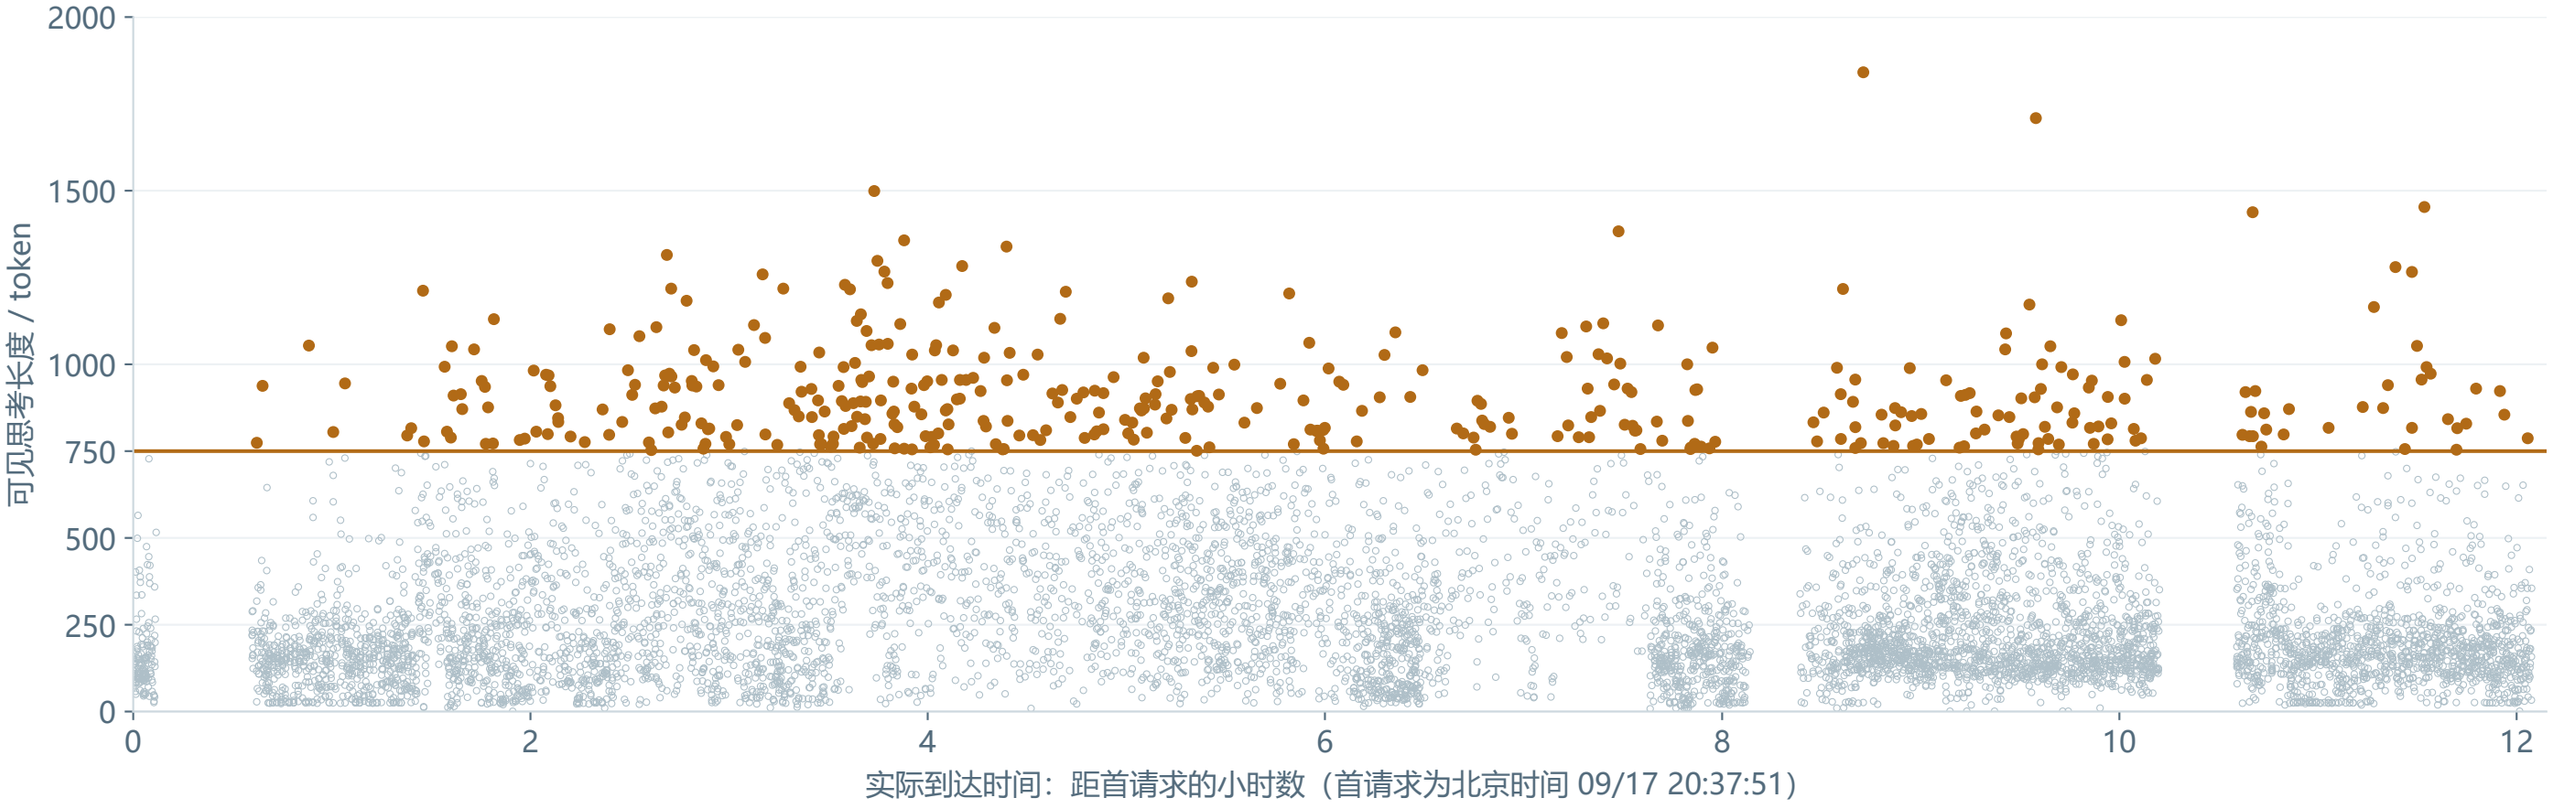
核心网运维 Agent 的 Vanilla 思考长度分布

有效请求 8,277 条；每点一条请求，金色点为 >750，金线为750 token介入参考线



7,862 条（94.99%）≤750　　415 条（5.01%）>750　　P50 / P95 / P99 = 207 / 753 / 1,002

采集 baseline 标记，服务端原生开关未独立确认。主请求排除29条，辅助3,908条另列。多数请求总输出上限2048。
阈值只标记候选介入范围，不代表实际旁路率、可安全删除量或实测收益。